ТЕХНИЧЕСКОЕ ЗАДАНИЕ НА РАЗРАБОТКУ «АВТОМАТИЗИРОВАННОЙ СИСТЕМЫ НОРМОКОНТРОЛЯ ВКР»

1. Общие положения

1.1. Наименование системы:

Автоматизированная система нормоконтроля выпускных квалификационных работ (далее – Система).

1.2. Назначение:

Автоматизация процесса проверки оформления студенческих работ (ВКР) форматов .docx на соответствие требованиям ГОСТ 7.32-2017 и локальным методическим указаниям кафедры.

1.3. Цели создания:

- Снижение рутинной нагрузки на преподавателей-нормоконтролеров.
- Ускорение обратной связи для студентов (отчет генерируется за 30-180 секунд вместо нескольких дней ожидания).
- Выявление попыток обхода антиплагиата (подмена символов кириллицы и латиницы).

2. Требования к архитектуре и стеку технологий

2.1. Формат работы: Клиент-серверная архитектура (SPA frontend + REST API backend).

2.2. Технологический стек:

- **Backend**: Python 3.10+, FastAPI.
- **СУБД**: PostgreSQL (реляционные данные, JSONB для профилей и отчетов).
- **Брокер очередей и кэш**: Redis.
- **Фоновая обработка**: Celery.
- **Микросервис PDF-конвертации**: Gotenberg (Docker-контейнер).

Москва 2026

- **Анализ файлов**: python-docx, lxml (работа с XML Word), PyMuPDF (работа с PDF).
- **Frontend**: React 18, Vite.
- **Деплой**: Docker, Docker Compose.

3. Функциональные требования

Система должна реализовывать следующий функционал:

3.1. Для пользователя (Студент/Преподаватель):

- Загрузка документа формата .docx размером до 50 МБ.
- Выбор профиля проверки (например, «Базовый ГОСТ» или «Требования кафедры 2025»).
- Отображение статуса обработки файла в реальном времени (в очереди, обрабатывается, готово).
- Просмотр детализированного отчета об ошибках.
- В отчете должны отображаться точные координаты нарушения (номер страницы, номер абзаца, фрагмент текста с ошибкой).

3.2. Для администратора системы (Методист):

1. Создание, редактирование и удаление «Профилей нормоконтроля».
2. Настройка параметров правил без изменения исходного кода (например, изменение требуемого размера шрифта с 14 пт на 12 пт, изменение требуемого количества источников в списке литературы).

3.3. Ядро валидации (Конвейер проверки):

- Асинхронная проверка документа без блокировки веб-сервера.
- Извлечение метаданных документа (количество страниц, количество слов).
- Конвертация .docx в .pdf для визуальных проверок (геометрия таблиц, расположение номеров страниц).
- Применение массива правил согласно выбранному профилю.

- Генерация отчета со статистикой (всего ошибок, всего предупреждений, признак валидности).

4. Требования к бизнес-логике (Правила нормоконтроля)

Система должна в автоматическом режиме осуществлять проверку по следующим категориям:

4.1. Структура документа:

- Наличие обязательных разделов: Аннотация (на отдельной странице), Содержание, Введение, Заключение, Список использованных источников, Приложения.
- Наличие не менее 3 глав, содержащих выводы.
- Соответствие пунктов из раздела «Содержание» фактическим заголовкам в тексте.

4.2. Типографика и параметры страницы:

- Поля: левое 30 мм, правое 15 мм, верхнее и нижнее 20 мм.
- Шрифт: Times New Roman, 14 пт (12 пт допускается в таблицах).
- Межстрочный интервал: 1.5.
- Абзацный отступ: 1.25 см.
- Оформление заголовков: 1 уровень (заглавные буквы, по центру, без абзацного отступа, полужирный), 2 уровень (с прописной буквы, по левому краю с отступом, полужирный).
- Отсутствие номеров страниц на первых трех листах (Титул, Задание, Аннотация). Нумерация арабскими цифрами внизу по центру.
- Объем основной части документа (без приложений) строго в пределах 70-80 страниц.

4.3. Объекты (Таблицы, Иллюстрации, Листинги):

- Таблицы: Подпись сверху слева (формат: Таблица 1 – Название). Наличие надписей «Продолжение/Окончание таблицы» при разрывах страниц.
- Иллюстрации: Подпись снизу по центру. Сквозная нумерация.
- Наличие перекрестных ссылок в тексте на каждую таблицу и иллюстрацию.

4.4. Библиография и ссылки:

- Общее количество источников: не менее 50.
- Доля источников на иностранном языке: не менее 5%.
- Доля электронных ресурсов: не более 50%. Обязательное наличие фразы «(дата обращения: ...)» для URL-ссылок.
- Наличие ссылок в тексте на все указанные источники в квадратных скобках (вида [1], [1, 2], [1-5]).

4.5. Качество текста и борьба с читерством:

- Отсутствие многоуровневых списков в тексте.
- Выявление недопустимых англицизмов (по обновляемому словарю).
- Выявление попыток подмены символов (смешивание букв кириллицы и латиницы внутри одного слова).

5. Ограничения и исключения

Настоящим ТЗ фиксируется, что Система НЕ выполняет следующие функции:

- Проверка смысла: Система не оценивает смысловое содержание Введения, Заключения, актуальности и новизны темы.
- Генерация текста нейросетью: Система не определяет, был ли текст написан студентом или сгенерирован ИИ.

- Уникальность: Система не вычисляет процент оригинальности текста. Данный параметр вводится вручную на основе справки из внешних систем.
- Старые форматы: Файлы форматов .doc, .rtf, .pdf, .odt к проверке не принимаются

6. Нефункциональные требования (NFR)

6.1. Отказоустойчивость:

В случае сбоя или зависания микросервиса конвертации PDF (Gotenberg) длительностью более 30 секунд, Система не должна прерывать работу. Визуальные проверки, зависящие от PDF, пропускаются с пометкой WARNING, остальные структурные проверки завершаются штатно.

6.2. Изоляция файлов:

Загруженные файлы сохраняются во временное хранилище и гарантированно удаляются (независимо от успеха или сбоя проверки) по завершении работы процесса или по истечении 1 часа через фоновый планировщик.

6.3. Производительность:

Время ответа API на загрузку документа и постановку в очередь: не более 5 секунд.

Время полной обработки 100-страничного документа (включая конвертацию): не более 180 сек (при наличии свободных воркеров).

7. Этапы реализации

Этап 1: Инфраструктура. Поднятие окружения (Docker, FastAPI, PostgreSQL, Celery, Redis). Проектирование БД.

Этап 2: Парсинг и DTO. Написание экстракторов (docx, pdf, app.xml) и механизмов очистки файлов.

Этап 3: Движок правил. Реализация паттерна Strategy, системы профилей и пайплайна валидации.

Этап 4: Бизнес-логика. Кодирование 39 правил согласно п.4 данного ТЗ.

Этап 5: Frontend. Реализация пользовательского интерфейса, отображение детализированного JSON-отчета.

Этап 6: Тестирование. Покрытие модульными и интеграционными тестами на наборе тестовых документов (с ошибками и без).